

COVID-19 社交媒体舆论注意力结构分析

疫苗 vs. 远程办公

严之皓

2026 年 1 月 8 日

1. 背景与目标

- 背景: COVID-19 期间, 社交媒体上出现了大量与疫情相关的讨论。
- 研究问题: 不同话题的讨论是否呈现不同的注意力分布——更集中, 还是更分散?
- 对比对象:
 - 疫苗话题: 健康政策、接种经历、副作用等个人分享。
 - 远程办公话题: 工作方式变化、生活节奏调整、经济与职业影响。
- 目标: 对比两类话题的讨论结构, 判断它们更偏“去中心化”的大众参与, 还是“中心化”的头部账号主导。

Pipeline:

- ① **Clean:** 文本清洗与标准化、去重。
- ② **EDA:** 基础分布探索与数据审计。
- ③ **Cluster:** Embeddings + K-Means 聚类。
- ④ **Label:** LLM 辅助的语义标注。
- ⑤ **Metrics:** 生命周期与基尼系数计算。
- ⑥ **Model:** WLS 统计回归建模。
- ⑦ **Robustness:** 多维度稳健性检验。

数据来源与采集方式

数据来源: X (Twitter) 公开搜索结果 (2020-2024)

采集方式:

- 使用 **Selenium** 自动化爬取搜索结果页面 (模拟滚动加载与分页)
- 按关键词布尔查询检索, 与时间条件共同限定数据范围

搜索 Query:

("COVID-19" OR "coronavirus" OR "COVID" OR "vaccine" OR "vaccination" OR "remote working" OR "work from home" OR "WFH") since:xxxx-xx-xx until:xxxx-xx-xx

数据规模:

- 推文条数: **4243**
- 字段数: **8** (text, replies, retweets, likes, views, author_name, author_handle, publication_time)

注: 仅采集公开可见内容; 后续分析在清洗阶段对重复/刷屏记录做了去重处理。

2. 数据清洗

任务: 对非结构化文本进行标准化, 去除噪音。



```
# src/clean.py
def normalize_text_column(text):
    text = text.lower()
    # 替换 URL
    text = re.sub(r'http\S+|www\.\S+', '<URL>', text)
    # 替换用户提及
    text = re.sub(r'@\w+', '<USER>', text)
    # 替换 Hashtag 为通用标记
    text = re.sub(r'#\w+', '<HASHTAG>', text)
    # 压缩多余空格
    text = re.sub(r'\s+', ' ', text).strip()
    return text
```

去重策略: 针对(作者, 时间, 文本)完全一致的记录, 仅保留互动量最高的一条, 防止机器人刷屏干扰。


3. EDA: 互动量分布

长尾分布 (Long-Tail)

- 点赞数呈现典型的幂律分布。
- 建模前必须进行 $\log_{1p}$ 对数变换。



3. EDA: 基线不平等



洛伦兹曲线

- 曲线严重偏离对角线（绝对平等线）。
- 前 20% 的作者占据了超过 80% 的总关注度。
- 全局基尼系数 ≈ 0.84 。


4. 向量化与聚类

方法: embedding + K-Means (网格搜索最佳 K)

K 的尝试搜索:

- 在区间 $K \in [\text{min_k}, \text{max_k}]$ 内逐一训练
- 使用 轮廓系数 (**Silhouette Score**) 选择最优 K

```
# src/cluster.py (grid search for K)
best_k, best_score = None, -1
for k in range(min_k, max_k + 1):
    kmeans = KMeans(n_clusters=k, random_stat
    labels = kmeans.fit_predict(matrix)
    score = silhouette_score(matrix, labels)
    if score > best_score:
        best_k, best_score = k, score
```



PCA 投影可视化

5. LLM 语义标注


目标: 将 Topic ID 转换为可解释的主题标签, 并生成可用于后续统计的结构化字段。

模型: qwen3-max

每个 **Topic** 输入: TF-IDF 关键词 + 质心样本 (与聚类中心距离最小的推文 20 条) + 高赞样本 (Top likes 5)

```
{  
  "topic_id": 2,  
  "topic_label": "Remote Work Opportunities",  
  "high_level_category": "remote_work",  
  "frame_tags": ["job_search", "flexible_work",  
    "online_applications", "career_advice"],  
  "stance_profile": {  
    "mostly_informational": 0.95,  
    "mostly_personal_experience": 0.03,  
    "mostly_policy_or_advocacy": 0.01,  
    "mostly_argument_or_conflict": 0.01  
  },  
  "representative_keywords":  
    ["remote", "work", "home", "job", "apply", "customer"]  
}
```


6. 话题生命周期



- 疫苗话题 (脉冲式): 由新闻事件 (如强制令发布) 驱动, 爆发快, 消退快。
- 远程办公 (长流式): 持续性的生活方式讨论, 热度平稳。

7. 注意力不平等

问题：谁主导了对话？




发现：远程办公（蓝线）的基尼系数始终高于疫苗（红线），说明其讨论更加中心化。

7. 各话题基尼系数对比

发现:

- 红色条目（疫苗）普遍较短。
- 蓝色条目（远程办公）普遍较长。



8. 统计建模 (WLS)

为控制时间趋势与样本规模差异，构建加权回归模型（权重 = $N_{authors}$ ）：



$$Gini \sim Category \times Time + \log(N_{authors})$$

```
# src/model.py  
formula = "gini ~ C(high_level_category) * month_index + np.log(n_authors)"  
model = smf.wls(formula=formula, data=df, weights=df['n_authors'])
```

结果：

- **vaccine vs remote_work**（基线差异）：coef = **-0.234**, $p < 0.001$
- 交互项 **vaccine × time**：不显著（ $p = 0.823$ ），差异随时间变化不明显
- 控制变量 $\log(N_{authors})$ ：coef = **+0.068**, $p = 0.026$

9. 稳健性检验



- 1 指标稳健性: 转发数 vs 点赞数 ($r = 0.89$)。
- 2 去头部效应: 剔除 Top 1
- 3 样本阈值: $N \geq 20$ vs $N \geq 10 \rightarrow$ 趋势高度一致。

10. 结论

在同一疫情语境下，不同话题的注意力分布并不一样

- 讨论结构：远程办公话题更中心化，注意力集中在少数高影响力账号；疫苗话题相对更分散
- 时间稳定性：这种差异在多个时间段都能观察到（话题 $\times$ 时间项不显著）
- 作者规模效应：参与作者越多 ($\log N_{authors}$)，注意力不平等程度越高

方法与实现：无监督聚类 + LLM 辅助主题归纳 + 基尼/生命周期指标 + WLS 回归

社交媒体并非“同一种公共空间”，传播策略可能需要根据议题特点进行调整。